



PONTIFICIA UNIVERSIDAD CATOLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y
COMPUTACIONAL

UC CHRISTUS: SISTEMA DE TAMIZAJE DE ATRESIA BILIAR A PARTIR DE IMÁGENES FECALES

**MARTÍN EDUARDO ALCÁNTARA GODOY
NICOLÁS ANTONIO DONOSO BARRAZA**

Proyecto de Grado para optar al grado de Ingeniero Civil
Matemático y Computacional

Santiago de Chile, 2026



PONTIFICIA UNIVERSIDAD CATOLICA DE CHILE
INSTITUTO DE INGENIERÍA MATEMÁTICA Y COMPUTACIONAL

UC CHRISTUS: SISTEMA DE TAMIZAJE DE ATRESIA BILIAR A PARTIR DE IMÁGENES FECALES

**MARTÍN EDUARDO ALCÁNTARA GODOY
NICOLÁS ANTONIO DONOSO BARRAZA**

Trabajo de Grado presentado a la Comisión integrada por los
profesores:

ALEJANDRO ENRIQUE CATALDO CORNEJO

DANIEL IGNACIO ZÚÑIGA FICA

DR. JUAN CARLOS PATTILLO SILVA

Para completar las exigencias del grado de Ingeniero Civil
Matemático y Computacional

Santiago de Chile, 2026

A la coti, que me hizo ver la luz en mis momentos más oscuros. A mis padres, que decidieron confiar en mí en mis estudios. - Martín.

A mis padres, que siempre me ayudaron a mantenerme con todo lo necesario para concentrarme en mis estudios - Nicolás.

AGRADECIMIENTOS

Agradecemos al Dr. Pattillo, y a Ana Campos por el trabajo realizado y la oportunidad de colaborar en este proyecto. Similarmente, agradecemos al cuerpo docente por la disposición a responder nuestras preguntas respecto al trabajo a realizar, o posibles mejoras o soluciones a los diversos obstáculos que fueron apareciendo.

Adicionalmente, agradecemos a todos los compañeros que se sentaron a escuchar el trabajo que realizamos, en especial a aquellos que nos aportaron su perspectiva y posibles soluciones cuando estábamos estancados.

INDICE GENERAL

DEDICATORIA.....	3
AGRADECIMIENTOS.....	4
INDICE GENERAL	5
INDICE DE FIGURAS	7
RESUMEN	8
ABSTRACT	9
1. Introducción	10
1.1. Contexto de la empresa y proyecto	11
1.2. Objetivos del proyecto.....	11
1.3. Atresia Biliar y SCC	11
2. Análisis de datos	14
2.1. Descripción de datos.....	14
2.2. Relación LAB y RGB.....	14
3. Modelo de tamizaje automático de atresia biliar	18
3.1. Preprocesamiento de la imagen	18
3.2. Segmentación	19
3.2.1. Descripción	19
3.2.2. Entrenamiento	19
3.2.3. Justificación	21
3.3. Vectorización.....	21
3.3.1. Descripción	22
3.3.2. Entrenamiento	22
3.3.3. Justificación	22
3.4. Clasificación	23
3.4.1. Descripción	23
3.4.2. Entrenamiento	23
3.4.3. Justificación	24
3.5. Implementación del modelo	25

4.	Trabajo propuesto y futuro	26
4.1.	Supuestos sobre los datos e imágenes	26
4.2.	Vectorizaciones alternativas	26
4.3.	Selección de hiperparámetros	27
4.4.	Modificaciones en el espacio de colores	28
5.	Compromisos y entregables	29
5.1.	Compromisos y entregables acordados por el equipo de trabajo	29
5.1.1.	Repositorio de GitHub	29
5.1.2.	Instructivo de uso	29
5.2.	Compromisos y responsabilidades de la contraparte	29
6.	Conclusiones	31
6.1.	Limitaciones	31
6.2.	Análisis	32
6.3.	Conclusiones	32
	ANEXO	34
1.	Trabajo realizado	34
	BIBLIOGRAFIA	36

INDICE DE FIGURAS

Figura 1.1: Stool Color Card.	12
Figura 2.1: Segmentación RGB de una sección de la SCC de ejemplo	15
Figura 2.2: Segmentación Lab de una sección de la SCC de ejemplo	16
Figura 3.1: Segmentación de una imagen de atresia biliar negativo.	20
Figura 3.2: Segmentación de una imagen de atresia biliar positivo.	21
Figura A.1: Carta Gantt asociada al proyecto.	35

RESUMEN

El proyecto descrito en el presente informe busca diseñar y realizar un prototipo de tamizaje visual de acolia a partir de imágenes fecales de infantes. La importancia del modelo radica en la conexión entre la acolia y atresia biliar; enfermedad que representa la principal razón de trasplante de hígado en infantes. Dentro de los métodos utilizados hoy en día está la Stool Color Card (SCC), la cual ilustra colores de heces asociados a acolia, para que los parientes evalúen si asistir a un pediatra. En este contexto, la SCC guía al modelo en la detección de acolia.

Se tiene acceso a imágenes de los depósitos de 20 infantes, divididos equitativamente entre pacientes con atresia biliar positiva y negativa. Se identifica que una transformación del espacio RGB al LAB sería indicado para analizar los datos.

El prototipo realizado se divide en tres partes. La primera se encarga de localizar dentro de una imagen el área de las deposiciones. La segunda busca reducir la información del área de interés a un sólo vector. La tercera corresponde a una regresión, que sirve para la clasificación efectiva del dato, frente a la presencia de acolia.

Se priorizó la interpretabilidad del modelo, manteniendo como fin el ser entrenado a futuro con un mayor número de datos. De esta manera, se deben ajustar los parámetros que definen los procedimientos de cada sección del modelo final, para así clasificar de buena manera un conjunto de datos representativos de la población.

En conclusión, el modelo realizado cumple con los objetivos, y representa un buen punto de partida para un entrenamiento futuro. El modelo es interpretable, con justificación de toda componente individual, para así ser ajustado a futuro con la implementación de nueva información en forma de imágenes de infantes con y sin presencia de acolia.

ABSTRACT

The project detailed in the present report aims to design and create a prototype for visual screening of acholia based on fecal images of newborns. The relevance of this model rests on the connection between acholia and biliary atresia, a condition that affects newborn and corresponds to the primary reason for liver transplants in this group. Within the standard methodology used in modern times lies the Stool Color Card (SCC), a chart that details colors for depositions with risk of acholia, such that a relative can gauge whether or not to seek medical attention. In this context, the SCC helps the model with base images to guide acholia detection.

The data we have access to correspond to 20 images of labeled patients' feces, divided between 10 healthy newborns and 10 patients with biliary atresia. Due to an analysis of the given data, as well as an SCC example, it was determined that a transformation from the RGB color space to the LAB space is beneficial to classify the fecal images. Utilizing the amount and type of images described, we successfully created a prototype for visual screening of acholia based on fecal images of newborns.

The proposed solution is defined as a general model subdivided into three separate tasks. Firstly, the model aims to localize a region with certainty to contain feces. Secondly, the model vectorizes said region, as to extract only the pivotal information. Thirdly, the model performs a regression on the new data, and classifies it, based on a pretrained model, according to the presence of acholia, or lack thereof.

With the objectives and limitations of the project in mind, we prioritized the interpretability of the current model, so that it can be trained with a larger number of images. In particular, the parameters that define each segment of the current model need to be adjusted in order to classify correctly a dataset that is representative of the larger population. In the future, there should be an overall evaluation of the model, modifying different aspects of the implementation. This evaluation can follow the different suggestions detailed in the present report.

In conclusion, the described model satisfies the objectives and requirements, and meets the criteria for a starting point for future training. The model has high interpretability, with justified assumptions and components, and is therefore a good candidate for the identification of acholia.

1. INTRODUCCIÓN

Frente a todo proyecto, es necesario entender el contexto sobre el cual se va a trabajar antes de definir un modelo o solución adecuada. Con esto en mente, se definirá primero el marco contextual bajo el cual se trabajará, para luego describir la solución propuesta ante la problemática. En adelante, se entenderá como proyecto al conjunto total de tareas, responsabilidades, y compromisos, según definidos por el Instituto de Ingeniería Matemática y Computacional, a través del curso IMT3500 - Taller de Ingeniería Matemática, el cual tendrá como título Sistema de Tamizaje de Atresia Biliar a Partir de Imágenes Fecales.

Se entenderá como equipo de trabajo, o simplemente el equipo, a los estudiantes que cursan dicha asignatura, y trabajan en el presente proyecto. Como empresa contraparte, o simplemente la contraparte, a UC Christus, al ser la entidad que solicita el trabajo descrito en el proyecto. Finalmente, se entenderá como informe al presente documento, cuyo fin es la descripción detallada del proyecto.

Posterior al contexto, se detallará la solución propuesta como un modelo de clasificación desarrollado en Python, en adelante, el modelo. En particular, este modelo se desarrolló en el contexto de una eventual aplicación con fines de tamizaje de atresia biliar, para uso general y público. En este sentido, el modelo se utilizará dentro de la eventual aplicación para realizar el tamizaje a partir de imágenes fecales adquiridas en la misma aplicación.

Finalmente, se describen los lineamientos del proyecto, tanto sobre los resultados esperados, como los resultados que no se esperan obtener en el marco del proyecto. Adicionalmente, se describen los compromisos del equipo de trabajo y de la empresa contraparte, y se detalla la planificación de tareas definidas para el equipo.

Existen diversas maneras de resolver el problema actual, pero el modelo descrito en el presente informe es el que mejor resuelve las necesidades de la contraparte. Cabe destacar que la implementación futura del modelo dentro de una aplicación define el contexto de los objetivos delimitados, y las restricciones implícitas al trabajo realizado, pero el desarrollo de la aplicación no está dentro del alcance del proyecto. En otras palabras, el presente proyecto se limita al desarrollo y evaluación de un módulo preliminar de análisis de imágenes para la detección de acolia.

1.1. Contexto de la empresa y proyecto

Este proyecto se realizó en conjunto con UC Christus, en particular con el Doctor Juan Carlos Patillo, director médico de UC Christus. UC Christus es una red de atención médica privada, asociados con la Pontificia Universidad Católica de Chile mediante la Christus Health. El Doctor Patillo es coordinador del Programa de Trasplante Hepático Pediátrico, con un especial interés en iniciativas de alto impacto en su área (UC Christus, 2023).

Con el contexto de la contraparte se puede verificar que les es de alto interés solucionar problemas relacionados con el trasplante hepático pediátrico. En particular, se tratará con la atresia biliar, que es una de las principales causas de trasplante hepático en infantes (Dugdale et al., 2024).

1.2. Objetivos del proyecto

El presente proyecto tiene como objetivo general la detección temprana, precisa y automática de acolia en las deposiciones de infantes, como tamizaje de atresia biliar. Con este objetivo en mente, se diseñará y realizará un prototipo de tamizaje visual de acolia a partir de imágenes fecales. En un final, el modelo devolvería una predicción de si la imagen proveída presenta riesgo suficiente como para que sea recomendable asistir a un pediatra. Se justificará más adelante, pero cabe destacar que no se promete una correcta detección de acolia, sino que un modelo que se pueda entrenar a futuro, y que esté correctamente documentado.

Este objetivo se desglosa en cinco objetivos específicos. Primero, contar con una base de datos inicial preprocesada y bien etiquetada. Segundo, la detección de una zona con información fecal para cada imagen. Tercero, la extracción de características fundamentales del color para dicha zona. Cuarto, la clasificación de presencia o ausencia de acolia en la imagen. Y quinto, la conexión integral de los procesos en un único pipeline funcional.

1.3. Atresia Biliar y SCC

La atresia biliar se refiere a una obstrucción de ductos que transportan bilis desde el hígado hasta la vesícula biliar. Esta es una enfermedad que afecta principalmente a recién nacidos, con una mortalidad elevada si no se realiza un trasplante de hígado. Las causas de esta enfermedad no son claras, por lo que la prevención no está completamente clara, pero se pueden identificar síntomas como la acolia (ausencia de pigmentos) en las deposiciones (Dugdale et al., 2024). Adicionalmente, es clave notar que esta enfermedad afecta a aproximadamente 1

entre 10.000 a 20.000 infantes, representando una de las principales causas de trasplante de hígado en infantes (Borgeat et al., 2018).

El principal tratamiento para la atresia biliar solo resulta efectivo si se detecta el problema en los primeros 60 días de vida, por lo que la detección temprana es esencial para evitar secuelas crónicas. Es por esta necesidad de detección temprana que se requieren de métodos para que los parientes identifiquen que el neonato tiene necesidad de acudir a un pediatra.

Una de las principales herramientas de tamizaje es la Stool Color Card (SCC). La SCC es una carta que contiene colores de referencia con los cuales identificar si los depósitos de los infantes presentan acolia o no. Se puede observar un ejemplo de SCC en la Figura 1.1. Esta herramienta se utiliza como una guía para que los parientes comparen con los colores de los depósitos de los infantes y decidir si llevarlo al pediatra o no. Se ha estudiado la eficacia de las SCC para identificar tempranamente la atresia biliar, y ha mostrado resultados favorables (Borgeat et al., 2018).




Figura 1.1: Stool Color Card.

Fuente : Hôpitaux universitaires de Genève, (2018).

A modo de análisis visual de la SCC, observamos que los colores en el rango normal tienen menos énfasis en la claridad. En particular, la combinación de los parámetros RGB de

cada uno de los colores anormales presentan valores elevados, lo que se traduce a colores más pálidos. Esta diferencia visual es lo que eventualmente se quiere captar con la utilización de un modelo de clasificación utilizando como referencia la SCC.

2. ANÁLISIS DE DATOS

En esta sección se presenta un análisis de los datos a los que se tiene acceso para el presente proyecto. Cabe mencionar que los datos se obtuvieron directamente de la contraparte.

2.1. Descripción de datos

Los datos a los que se tiene acceso son imágenes de depósitos fecales de infantes. Estos datos se encuentran etiquetados como infantes con atresia biliar e infantes sanos sin atresia biliar. Cabe destacar que la clasificación de atresia biliar fue proveída por un profesional calificado.

Las imágenes fueron tomadas con un mismo celular para todos los casos, por lo que el tamaño de las imágenes no varía entre ejemplares (1200x1600 px). En cuanto a calidad de los datos, observamos que en general se puede observar una zona de depósitos fecales clara, otras que el color se confunde con el entorno, y hay casos bordes que son especialmente irregulares en la presentación.

Por último, la cantidad de imágenes a las que se tuvo acceso para este proyecto fue de 20, divididas entre 10 imágenes de infantes con atresia biliar, y 10 infantes sanos. En un proyecto similar, Roberta Angelico y su equipo de investigación (2020) muestran que una cantidad de imágenes bordeando los 40 no es suficiente para extraer conclusiones sólidas, afirmando que 160 sería un número aceptable para confiar en la precisión que presente un modelo de machine learning para identificar acolia en imágenes. En este sentido, la cantidad de datos es baja, lo que modifica el tipo de conclusiones que se pueden extraer en base a la implementación de cualquier modelo sobre los datos.

2.2. Relación LAB y RGB

Dentro de la exploración, se observó que una manera para clasificar las imágenes incluye una correcta separación de los parámetros que describen la imagen. En general, se describen las imágenes mediante los valores RGB, pero se observó que para este caso, una mejor división se puede obtener mediante la transformación del espacio RGB al espacio LAB. El espacio LAB codifica la información de los colores en las dimensiones A y B , definidas como los ejes entre los colores verde y rojo, y azul y amarillo respectivamente, mientras que la componente L codifica la luminosidad de la imagen. Para ver la división entre espacios RGB y LAB, observamos como ejemplo el SCC.




Figura 2.1: Segmentación RGB de una sección de la SCC de ejemplo

Descripción: De izquierda a derecha, podemos observar la SCC en su forma original, seguido de las componentes R, G y B respectivamente, donde el color amarillo representa un mayor valor. Los tres colores de abajo representan la presencia de acolia y por tanto de un factor de riesgo.




Figura 2.2: Segmentación Lab de una sección de la SCC de ejemplo

Descripción: De izquierda a derecha, podemos observar la SCC en su forma original, seguido de las componentes L, A y B respectivamente, donde el color amarillo representa un mayor valor. Los tres colores de abajo representan la presencia de acolia y por tanto de un factor de riesgo.

En este ejemplo, podemos notar como, si bien existen ciertas diferencias en el espacio RGB, no es tan claro visualmente la división entre las distintas categorías en cada componente del espacio. En particular, en la dimensión R, parece haber un aumento en el valor de R a medida que uno se acerca a los resultados de acolia, pero aún así, parece disminuir nuevamente a medida que uno entra en la zona de acolia. En el resto de dimensiones si se logra observar cierta división, pero puede no ser tan notoria como la división en la reestructuración LAB. En la dimensión LAB, notamos claras diferencias en el espacio L y B. En el eje L se puede apreciar un aumento a medida que uno baja en los colores tipo de una SCC, lo que se puede explicar por la aparente claridad de las muestras con acolia. Por otro lado, vemos en el eje B que el grupo de imágenes con acolia están propiamente separados del resto. Esta división del espacio B es consistente con ciertas conversaciones con la contraparte, en que se detalla que evaluar la

intensidad del color amarillo puede ser efectivo para la clasificación, ya que la dimensión B es interpretable como una partición entre azul y amarillo.

3. MODELO DE TAMIZAJE AUTOMÁTICO DE ATRESIA BILIAR

El trabajo realizado consiste en detectar, a partir de un análisis de imágenes, la presencia o ausencia de acolia. Este consiste en el principal indicador dentro del tamizaje de Atresia Biliar. Trabajos similares han mostrado resultados prometedores (Angelico et al., 2020 & Poocharoen et al., 2024), pero no han sido replicados en Chile hasta la fecha. En particular, se trabajará en el desarrollo del método predictivo, en cuanto a su formulación computacional. Este será descrito en la presente sección, tanto en su descripción, como su implementación y método de uso. En adelante, se entenderá como modelo al sistema predictor en su completitud, o a cualquiera de sus partes, de manera indistinta.

Posterior a un preprocesamiento de las imágenes, el modelo se define como un procedimiento secuencial separado en tres tareas. Primero, se buscará identificar y segmentar las deposiciones a partir de la imagen, obteniendo un recorte que contenga únicamente esta información. Segundo, se realizará una vectorización de la imagen a partir del segmento obtenido, la cual busca codificar la información relevante para el estudio y tamizaje. Tercero, a partir de un modelo de clasificación, se le asignará un valor en el intervalo unitario a dicho vector, a partir del cual se realiza una decisión frente a la presencia de acolia.

3.1. Preprocesamiento de la imagen

Es necesario recordar que el modelo desarrollado será eventualmente incorporado a una aplicación móvil, que tomará imágenes con la cámara del dispositivo. Estas, en su gran mayoría, son almacenadas y trabajadas como estructuras de dimensiones $H \times W \times 3$, almacenando los colores en tres dimensiones, en el espacio RGB, donde H, W son la altura y el ancho de la imagen, respectivamente.

Considerando la exploración inicial de los datos, trabajaremos con una transformación continua no lineal al espacio LAB. Este nuevo espacio codifica la información de los colores en las dimensiones A y B , definidas como los ejes entre los colores verde y rojo, y azul y amarillo respectivamente, mientras que la componente L codifica la luminosidad de la imagen.

En adelante, entenderemos como imagen a aquellas estructuras en formato LAB de tamaño $H \times W \times 3$, y como capas a la separación de una imagen en sus tres componentes; a las estructuras de tamaño $H \times W$ que conforman la imagen. Las visualizaciones y figuras son generadas a partir de su versión en el espacio RGB por simplicidad.

3.2. Segmentación

En primer lugar, el modelo recibirá una imagen como entrada, correspondiendo a un pañal blanco, con feces de un infante en su interior. Luego, la salida del modelo correspondería a una segunda imagen, incluyendo únicamente la o las regiones que contengan depósitos. En caso de no encontrar una región con depósitos, el modelo entregaría un error.

3.2.1. Descripción

Para construir la imagen de salida, se construirán máscaras sobre las capas de la imagen de entrada, restringiendo sus valores a ciertos intervalos. Esto es, se obtendrán estructuras binarias de tamaño $W \times H$, con valor 1 sí y solo sí el valor asociado en la capa correspondiente se encuentra dentro del intervalo. Luego, se combinan las tres capas en una única máscara combinada, la cual correspondería a la región de interés. De esta manera, la imagen de salida correspondería a la imagen de entrada, restringida a la región definida por la máscara combinada.

3.2.2. Entrenamiento

El primer paso en la segmentación corresponde a obtener una máscara para cada capa. La diferencia en cada máscara corresponde a los límites del intervalo que la define, y por ende no se hará distinción en su definición. De esta manera, sea C una capa, definimos la máscara de parámetros l_c, u_c como la matriz $M^{(c)}$ tal que:

$$M_{i,j}^{(c)} = \begin{cases} 1, & \text{si } C_{i,j} \in [l_c, u_c] \\ 0, & \text{si } C_{i,j} \notin [l_c, u_c] \end{cases} \quad (3.1)$$

Con esto en mente, bastaría entrenar sobre los parámetros l_c, u_c hasta encontrar valores adecuados para generar máscaras globales. Sin embargo, las figuras 3.1 y 3.2 nos muestra que la elección de estos parámetros no solo no es trivial, sino que puede no existir según esta definición, siendo necesario más de un intervalo para identificar diferentes casos de deposiciones, tanto inter- como intracategoría. Por ello, se definen los límites de manera independiente para cada capa, utilizando el método de Otsu (Brett, M., 2016), el cual el valor u que minimice la diferencia de variación entre los intervalos $[0, u], [u, 1]$. La dirección del intervalo se determinará según cuál defina una máscara más centrada.

Posterior a obtener las máscaras asociadas a cada una de las tres capas, basta obtener una máscara combinada a través del producto puntual de las tres matrices. Esto es, $M_{i,j} = M_{i,j}^{(L)} M_{i,j}^{(A)} M_{i,j}^{(B)}$, donde M corresponde a la máscara combinada. Sin embargo, esta máscara puede no ser adecuada en la práctica. Es por ello que, en lugar de utilizar la máscara en este estado, se obtiene el contorno de la región que le define. De esta manera, se pueden rellenar vacíos presentes por ruido en la imagen, o por variaciones falsamente rechazadas. Adicionalmente, se selecciona únicamente la componente conexas de mayor tamaño, para controlar el efecto del fondo de la imagen. Con estas correcciones es posible esperar una máscara sólida y conexas, conformada únicamente por el segmento de imagen correspondiente a las feces del infante.




Figura 3.1: Segmentación de una imagen de atresia biliar negativo.

Descripción: (A) Imagen original. (B)-(C)-(D) Capas asociadas a las componentes L, A, B de la imagen, respectivamente. (E) Máscara combinada y corregida. (F) Máscara sobre la capa L, definida como $L \leq 150$. (G) Máscara sobre la capa A, definida como $A \geq 128$. (H) Máscara sobre la capa B, definida como $B \geq 155$.




Figura 3.2: Segmentación de una imagen de atresia biliar positivo.

Descripción: (A) Imagen original. (B)-(C)-(D) Capas asociadas a las componentes L, A, B de la imagen, respectivamente. (E) Máscara combinada y corregida. (F) Máscara sobre la capa L, definida como $L \leq 190$. (G) Máscara sobre la capa A, definida como $A \leq 128$. (H) Máscara sobre la capa B, definida como $B \geq 140$.

3.2.3. Justificación

La pertinencia de lo descrito anteriormente está sujeta a tres supuestos sobre los datos. Primero, las imágenes analizadas corresponden a depósitos sobre un pañal blanco. Segundo, la imagen es tomada con el pañal y las heces en el centro, con fondo mínimo. Tercero, se tiene un control sobre la luminosidad de la imagen, como el flash de la cámara. Bajo estos supuestos, la validez es seguida de la sección anterior. Sin embargo, se describen posibles correcciones ante la ausencia de dichos supuestos en la siguiente sección.

3.3. Vectorización

En segundo lugar, el modelo vectorizará la imagen de entrada a partir de la región recortada, obtenida en el paso anterior. Este vector tomará el rol de vector representante para efectos de la clasificación final.

3.3.1. Descripción

En base a lo discutido anteriormente, la vectorización canónica corresponde a determinar un vector de color promedio de la región fecal. En particular, para una determinada imagen, se obtendrá el valor promedio para cada una de sus capas, y se almacenará en un único vector con tres entradas. Esta etapa es fundamental dado que representa la información relevante para el tamizaje, reduciendo la dimensión de los datos de entrenamiento, sin comprometer interpretabilidad.

3.3.2. Entrenamiento

La formulación actual del modelo utiliza la vectorización canónica de una imagen. Esto es, se realiza un promedio simple sobre las dimensiones H, W , restringido al segmento definido por la máscara, obteniendo un vector en tres dimensiones representando el color promedio de la región fecal. Por esta razón, no resulta necesario el entrenamiento de parámetros para esta tarea.

3.3.3. Justificación

En base a discusiones con la contraparte, y corroborado por la literatura explorada (Borgeat et al., 2018, Angelico et al., 2020, Dugdale et al., 2024), la presencia de acolia representa un indicador temprano, pero fundamental en el tamizaje de atresia biliar. Esto es, basta con evaluar el color de las deposiciones para levantar alerta hacia una evaluación médica. De esta manera, restringir el análisis de la imagen al color de la deposición resulta una extensión natural del uso de la Stool Color Card. No obstante, la elección del promedio natural como método de vectorización no es trivial, y tiene dos principales obstáculos.

Primero, dos imágenes notoriamente distintas pueden producir vectores arbitrariamente cercanos. Sin embargo, considerando que el promedio es acotado a la región con depósitos, se esperaría que estas imágenes correspondan al mismo diagnóstico frente a un tamizaje de atresia biliar utilizando métodos clásicos. Segundo, este valor puede no ser representativo a la muestra, con elevadas diferencias en los colores presentes en la región. Esto es parcialmente mitigado por la tarea de segmentación en sí, dado que el resultado son regiones con baja variación de colores. Sin embargo, debido a las correcciones utilizadas, y buscando ser conservadores las hipótesis de los datos, se proponen dos vectorizaciones alternativas que son discutidas en la siguiente sección.

3.4. Clasificación

En tercer lugar, el modelo obtendrá un valor entre 0 y 1, el cual será interpretado como indicador de factores de riesgo ante atresia biliar mediante presencia de acolia. En particular, se realizará una clasificación con un método supervisado previamente entrenado. La clasificación se realiza con umbrales apropiados sobre el valor final obtenido.

3.4.1. Descripción

El método seleccionado corresponde a un perceptrón de multicapa (MLP). Este método se escoge por su baja complejidad y alta interpretabilidad. En esencia, el método desarrollado realiza una tarea de regresión sobre los vectores representantes de tres dimensiones, con el fin de aprender su relación a un valor en el intervalo unitario. Luego, ante un nuevo dato, se estima dicho valor, el cual puede ser interpretado como la seguridad del modelo ante la presencia de acolia.

3.4.2. Entrenamiento

Se define el modelo como un MLP de dos capas ocultas de tamaños 64 y 32 respectivamente, con RELU como función de activación, y una última capa de output con función de activación sigmoide. Esto se puede entender como una regresión en la medida que se aprende la relación entre los datos y el output del MLP. La función del sigmoide es precisamente transformar este output a una clasificación supervisada. Cabe destacar que, al corresponder al tamizaje de una enfermedad de alto riesgo, es importante ser conservador y minimizar, a toda costa, los falsos negativos, lo que es determinar como sano a un recién nacido con atresia biliar positiva.

La tarea de regresión tiene, en esencia, muy pocas diferencias al entrenamiento de un método de regresión clásico. De esta manera, la metodología de entrenamiento corresponde a segmentar los datos en un grupo de entrenamiento, y otro de prueba, con el objetivo de entrenar los pesos del MLP. Luego, con el modelo entrenado, basta definir umbrales de decisión para el argumento de salida. Esto es, definir valores $t_0 < t_1 \in (0,1)$ tales que, sea t el output del regresor, si $t \in [0, t_0)$, el modelo rechaza la presencia de acolia; si $t \in (t_1, 1]$, el modelo determina la presencia de acolia como factor de riesgo de atresia biliar; y si $t \in [t_0, t_1]$, el modelo no tiene certeza sobre su decisión.

Existe una consideración importante que distingue el entrenamiento de esta sección de un modelo clásico. La consideración especial es que, además de tener datos etiquetados para el entrenamiento, se tienen vectores de referencia ampliamente aceptados para ambas categorías.

Teniendo en mente el estándar establecido por la Stool Color Card, es posible incorporar los colores definidos en ella en el entrenamiento del regresor. Esto es, sean el conjunto de vectores I los datos de entrenamiento, y J los vectores de colores presentes en la Stool Color Card, donde $|I| \gg |J|$, se define la función de pérdida como

$$\mathcal{L} := \sum_{i \in I} \omega_I \ell_I(f(x_i), y_i) + \sum_{j \in J} \omega_J \ell_J(f(x_i), y_i) \quad (3.2)$$

En donde f corresponde a la regresión, ω_I, ω_J son los pesos aprendidos de los grupos respectivos, y ℓ_I, ℓ_J son hiperparámetros de clasificación. De esta manera, es posible priorizar una correcta clasificación sobre los vectores de la Stool Color Card.

3.4.3. Justificación

Primero, considerando el consenso de la Stool Color Card como método apropiado de tamizaje, se asume la existencia de una hipersuperficie separadora en el espacio de colores que distinga las deposiciones con atresia biliar positiva, de aquellas con atresia biliar negativa y, por ende, no es necesario utilizar un método de mayor complejidad. Esto es, se asume suficiente una clasificación a partir únicamente de los vectores de colores representantes.

Segundo, se escoge un perceptrón de multicapa debido a su alta interpretabilidad. Esto es, al hacer uso de una función de activación apropiada, este obtiene un valor entre 0 y 1, que en este caso será la función sigmoide normalizada al intervalo de la unidad. Este procedimiento permite además una visualización de la superficie separadora.

Tercero, si bien existen alternativas de menor complejidad, como un support vector machine con kernel gaussiano, o árboles de decisión, se escoge un MLP debido a la facilidad de incorporar los datos de la Stool Color Card en el entrenamiento, así como una mayor facilidad de escalar en la medida que se recolecten más datos. Cabe destacar que el uso de otros modelos no está del todo descartado, y esta posibilidad se explora en mayor detalle en la siguiente sección.

3.5. Implementación del modelo

La implementación del modelo se realizó a través de un módulo de Python, utilizando la versión Python 3.12.9. El procesamiento de imágenes se realizó con la librería Opencv-Python versión 4.13.0.92, junto a NumPy 2.4.4, mientras que la visualización utilizó Matplotlib 3.10.1. Los modelos de regresión y clasificación utilizados se desarrollaron con la librería PyTorch 2.5.1+cu121. Las diferentes tareas del modelo se definieron como funciones y clases de Python con parámetros entrenables, a partir de funciones de pérdida adecuadas, y utilizando datos provistos por la contraparte para el entrenamiento supervisado preliminar.

4. TRABAJO PROPUESTO Y FUTURO

La presente sección tiene como objetivo definir las acciones necesarias para escalar el modelo descrito anteriormente a una mayor cantidad de datos de manera eficiente, así como los requerimientos implícitos de una eventual aplicación.

4.1. Supuestos sobre los datos e imágenes

En la justificación de la segmentación se enunciaron tres supuestos sobre las imágenes que son necesarios para el correcto funcionamiento del modelo. En una primera instancia, es posible requerir a los usuarios que tomen en consideración esto al tomar la fotografía, pero sería deseable obviar esto. El supuesto se puede relajar incluyendo YOLO en el pipeline (Sapkota et al., 2025). YOLO es un método de detección de objetos en tiempo real que permite detectar objetos y encapsularlos en un rectángulo. De esta manera, al incorporar YOLO a la interfaz de usuario, se logran relajar los tres supuestos sobre las imágenes iniciales.

Primero, es posible asegurar la presencia de depósitos con este método. Segundo, al usar únicamente la delimitación rectangular, se asegura un correcto alineamiento y centrado del pañal. Tercero, bajo el razonable supuesto de que todos los pañales sean blancos, sería posible ajustar la luminosidad de la imagen para estandarizar el color del pañal. De esta manera, se propone utilizar YOLO como filtro inicial de las imágenes. Cabe destacar que diversos estudios indican que YOLO resulta confiable al contar con al menos 150 imágenes, estabilizándose en las 500 imágenes (Shahinfar et al., 2020, Song et al., 2025).

4.2. Vectorizaciones alternativas

En caso de que se sospeche irregularidad en la densidad de colores en la región extraída, se definen dos vectorizaciones alternativas.

Primero, en lugar de realizar un promedio simple, es posible generar un promedio ponderado según la región. Es razonable suponer que las heces humanas no constituyen un bloque sólido y monocromático, sino una masa que se dispersa a partir de un punto focal, y pierde intensidad a medida que se disipa y esparce en una determinada región. Luego, ya sea el centro geométrico, o de mayor intensidad de colores, se define un foco a partir del cual se define un decaimiento gaussiano a partir de algún hiperparámetro σ , el cual se buscaría aprender. Esto se puede generalizar a múltiples focos, o incorporando una dependencia direccional al decaimiento, pero estos no forman parte de los métodos entregados.

Segundo, en lugar de clasificar un único vector promedio, se pueden clasificar más de uno, utilizando como variable predicha el promedio, o bien el máximo entre estos. Esto se podría realizar particionando la región en n partes iguales, pero esto no incorpora una distribución espacial de los colores. En su lugar, se propone utilizar un algoritmo de clustering según los colores, y promediar los segmentos encontrados. Específicamente, se propone utilizar KMeans, que busca generar clusters de colores similares. La versión propuesta tiene como parámetro un porcentaje p en lugar del número de clusters k . De esta manera, el valor de k se obtiene como la mayor cantidad de clusters que correspondan a al menos $p\%$ del tamaño de la imagen.

4.3. Selección de hiperparámetros

Como se menciona en un inicio, se muestra difícil la obtención de una gran cantidad de datos, lo cual limita el trabajo de refinamiento de hiperparámetros a lo largo del proyecto. Es por ello que, en la medida que aumenten los datos y se busque reentrenar y refinar los modelos, es necesario volver a testear y refinar los hiperparámetros. Para ello, se recomienda el uso del módulo de Python Optuna, debido a su flexibilidad y robustez para esta tarea, así como un apoyo visual del entrenamiento realizado. Las métricas para el entrenamiento de estos deben, como mínimo, incluir la minimización de falsos negativos, la maximización de accuracy en los datos de la SCC, y la pérdida marginal general de la optimización. Luego, los hiperparámetros a entrenar son la estructura del perceptrón multicapa, según el número y tamaño de las capas, el factor de penalización a los datos de la SCC, que se espera disminuya a medida que la muestra crezca, el learning rate del modelo, y los umbrales de decisión.

Además de esto, al obtener suficientes datos, es necesario reentrenar la red completa. Actualmente, con el fin de simular la presencia de más datos, se realizan promedios sobre regiones acotadas de cada imagen. En particular, se realiza una convolución de la imagen con un tamaño de ventana del 10% de la región, y un overlap de 5%. De esta manera, se genera, en el mejor de los casos, 121 vectores por cada imagen, aumentando el número de datos de entrenamiento. Esto, sin embargo, fue realizado únicamente con fines ilustrativos, dado que tiene un alto riesgo de overfitting, por lo que se recomienda deshabilitar esta funcionalidad una vez recolectadas 160 imágenes, como indica Angelico (2020).

4.4. Modificaciones en el espacio de colores

A lo largo del proyecto, se ha hecho uso del espacio de colores LAB, debido a presentar un mejor desempeño e interpretabilidad que el espacio RGB. Este obtiene buenos resultados, en especial en la tarea de segmentación. Sin embargo, es posible que para las siguientes tareas esta no sea la representación de colores óptima. Debido a que se busca detectar la presencia o ausencia de acolia, sería posible reducir aún más la dimensión del vector. En específico, el Dr. Pattillo propone evaluar la intensidad del color amarillo, lo cual es consistente con lo observado en la componente B de la representación actual. Es por ello que se propone incorporar coeficientes de penalización específicos para cada capa, o realizar una transformación adicional para encapsular este comportamiento específico.

5. COMPROMISOS Y ENTREGABLES

5.1. Compromisos y entregables acordados por el equipo de trabajo

Para efectos del proyecto se definen dos principales entregables por parte del equipo de trabajo a la contraparte, recordando que se restringe al desarrollo del modelo clasificador, el cual será posteriormente incorporado en la eventual aplicación.

5.1.1. Repositorio de GitHub

El módulo de Python en su completitud será almacenado en un repositorio de GitHub para libre uso de la empresa, junto a los datos utilizados para el entrenamiento, y todos los archivos generados como gráficos, modelos entrenados, entre otros. Este código estará adecuadamente comentado y explicado en un archivo README.md, el cual explicará su funcionamiento general y su modo de uso.

En particular, se tienen cinco scripts de Python: `segment.py`, `vector.py` and `model.py` definen las componentes de las tres tareas principales del problema, respectivamente, `update_model.py` se encarga del entrenamiento del modelo, y `viz.py` contiene herramientas para visualizar los resultados obtenidos. Adicionalmente, se tiene un notebook de tutorial en `tutorial.ipynb` que describe un ejemplo de uso. Finalmente, se tiene una carpeta de data que contiene el modelo entrenado completo, junto a los datos utilizados para entrenarlos como `model.pt` y `data.npz` respectivamente.

5.1.2. Instructivo de uso

En conjunto al archivo README y los comentarios presentes en el código, se desarrollará un documento asociado como instructivo de uso. El objetivo de este es ser usado como documentación, justificación de procesos y toma de decisiones a lo largo del proyecto. Se espera que con este código, la contraparte, o cualquier tercero asociado al desarrollo de la eventual aplicación, pueda hacer uso de toda parte del modelo desarrollado, así como realizar los ajustes necesarios.

5.2. Compromisos y responsabilidades de la contraparte

El proyecto consta, fundamentalmente, de tareas de regresión y aprendizaje de máquina. Es por ello que el rendimiento del modelo desarrollado es altamente sensible a la cantidad y

calidad de datos usados en su entrenamiento. Se entiende, entonces, que el estado final del producto entregado carece de validez estadística, y representa un modelo funcional y sujeto a ediciones con una mayor cantidad de datos. Por lo mismo, se asegura que la formulación del modelo permite una simple ejecución de esta tarea.

6. CONCLUSIONES

En esta sección se describen las principales limitaciones, análisis, y conclusiones del proyecto.

6.1. Limitaciones

La principal limitación sobre el alcance del proyecto radica en la ausencia de datos. En particular, para el análisis preliminar y la creación del modelo general se utilizaron 20 imágenes totales, divididas entre 10 imágenes de infantes sanos y 10 imágenes de infantes con atresia biliar.

Debido al bajo número de datos, no se puede justificar la implementación del modelo en un entorno de producción final. La principal razón es que cualquier métrica utilizada para medir el rendimiento del modelo estaría sesgada al conjunto de datos que se tiene inicialmente, por lo que no se podrían analizar potenciales casos bordes. Esto se puede verificar bibliográficamente, donde para efectos de clasificación, un número de imágenes más bajo que 40 sería insuficiente para extraer conclusiones generales (Angelico et al., 2020).

Otra limitación del proyecto actual sería el contexto sobre el cual se planteó inicialmente. Parte importante del contexto del proyecto en general, es que se va a utilizar una modificación del modelo final en una aplicación, con el objetivo de clasificar imágenes de depósitos de infantes y entregar un tamizaje a partir de ese resultado. Por lo mismo, el modelo general realizado en el presente informe se limita a imágenes fecales de infantes, de cualquier medida y calidad, que refleja el uso de un pariente promedio. En este sentido, el proyecto está limitado por la cantidad de casos para los que puede ser útil, formando así supuestos sobre las imágenes. Dentro de los supuestos más relevantes, se requiere que las deposiciones estén centradas en la imagen, con un pañal blanco, y se tiene control sobre la luminosidad de la imagen.

En un final, el proyecto realizado incorpora las limitaciones en el modelo final. En particular, el modelo final no está pensado para ser utilizado en producción final, puesto que no se puede asegurar con este conjunto de datos su correcto entrenamiento. Adicionalmente, notamos que es un modelo que debe ser utilizado sólo para imágenes centradas de feces de infantes, con el objetivo de clasificar si las imágenes presentan acolia.

Fuera de estas limitaciones, es necesario recalcar que en la solución general se describen los pasos necesarios para flexibilizar ciertas hipótesis y limitaciones en una implementación futura.

6.2. Análisis

En presencia de un modelo final, podemos observar que la solución entregada responde a los objetivos y limitaciones que provienen del contexto. En particular, observamos que la estructura general divide todo el procedimiento en tres secciones distintivas, donde cada una tiene un fin particular. Por lo mismo, podemos entender el flujo general en partes bien divididas, respondiendo así a la interpretabilidad requerida.

En la primera sección, se segmentan efectivamente las áreas en que se encuentran las deposiciones de los infantes. Esta segmentación se realiza bajo ciertas hipótesis razonables para el contexto en que se extraerán las imágenes, como lo serían depósitos centrados, un pañal blanco de fondo, y luminosidad controlada. A futuro quedaría evaluar si las especificaciones de cómo se obtienen las máscaras son adecuadas para un mayor conjunto de datos. Adicionalmente, se pueden evaluar las hipótesis individualmente, u ocupar YOLO como intermediario en este proceso.

En la segunda sección, se vectoriza una imagen desde la sección segmentada, a un solo vector. Actualmente se utiliza el promedio simple de la imagen resultante del paso anterior, y si bien esto está bien justificado, quedan pasos a evaluar en un futuro. Precisamente, se debería evaluar si la implementación de un vector con promedio gaussiano, o una serie de vectores, es justificable para una mayor muestra.

En la tercera sección de la solución, se clasifica mediante un MLP si los vectores introducidos representan riesgo de acolia o no mediante una función sigmoide. Esta implementación también es interpretable, entregando un valor entre 0 y 1, que puede ser visto como una probabilidad de que la imagen presente acolia o no. Por lo mismo, el ajuste de parámetros para esta sección debe tener en cuenta esta interpretación, así como las explicaciones de cada variable de la función de pérdida.

6.3. Conclusiones

En general, se logró llevar a cabo el objetivo de diseñar y realizar un modelo de tamizaje visual de acolia a partir de imágenes fecales. El modelo general planteado como solución,

responde a la necesidad de entregar una clasificación entre presencia o ausencia de acolia en una imagen dada. Se realiza esta tarea bajo supuestos razonables, en el contexto de una aplicación futura que implementaría una modificación del modelo detallado en el presente informe.

La solución desarrollada responde a las limitaciones que entrega el contexto. En particular, el contexto entrega la limitación de tipo de imágenes que se introducirán en el modelo, por lo que se esperan imágenes similares a las de entrenamiento, que relfejen la información necesaria para la correcta clasificación. Adicionalmente, se responde a la limitación de número de datos mediante la especificación de que el modelo debe ser reentrenado a futuro con un mayor número de imágenes, ajustando parámetros para entregar una correcta clasificación. Cabe destacar que en el entrenamiento futuro se puede hacer uso de las distintas variantes detalladas a lo largo de la descripción de la solución para efectivamente llegar a un resultado que priorice la baja de falsos negativos.

El modelo general está planteado como una serie de funciones que realizan la tarea de clasificación con priorización en la interpretabilidad y correcta justificación de cada paso. Al buscar sólo el diseño del modelo completo, no se realizó un entrenamiento final de sus componentes, dejando este procedimiento para un futuro en que se tengan suficientes datos. Esta distinción es importante recalcarla, pues por las limitaciones del proyecto, se requiere que un diseño general que pueda ser utilizado a futuro.

ANEXO

1. Trabajo realizado

Se establece una ruta de trabajo para el proyecto, resumida como Carta Gantt en la figura A.1. Esta se encuentra separada en cuatro categorías: la definición del problema, el desarrollo del software, el prototipo de la eventual aplicación, y los aspectos administrativos.

En primer lugar, se establecen las delimitantes del problema. Se define la propuesta de solución, en línea tanto de aquello que se buscará resolver, como de aquello que no se trabajará en el proyecto. Esto considera tanto investigación de trabajos similares, planteamientos y propuestas de solución por parte del equipo de trabajo, y el compromiso y definición de los entregables según detallados en el presente documento. Se establecen los objetivos principales y corrobora la correcta interpretación y entendimiento de la problemática que la contraparte busca resolver.

En segundo lugar, en base a la solución propuesta, se desarrolló el modelo de clasificación como una herramienta de software. Esta etapa consideró el mayor esfuerzo y cantidad de recursos, debido a ser el pilar fundamental del proyecto. Se incluye en esta fase las tareas de programación, entrenamiento, y ajustes necesarios para el correcto funcionamiento del modelo, bajo el marco de los datos obtenidos.

En tercer lugar, se detallan las acciones al modelo necesarias para la incorporación en una eventual aplicación. De esta manera, corresponde también a la definición y escritura del instructivo de uso adjunto como entregable.

En cuarto lugar, se cumplen con los requerimientos administrativos del proyecto, en vista de su rol como instrumento de evaluación y parte del proceso de titulación del equipo de trabajo, con el fin de optar al grado de Ingeniero Civil Matemático y Computacional, otorgado por la Pontificia Universidad Católica de Chile. Estas tareas son realizadas en la medida que se definen sus plazos académicos, y corresponden tanto a presentaciones parciales de avance, como la escritura del presente informe final de proyecto.




Figura A.1: Carta Gantt asociada al proyecto.

Descripción: Las primeras cuatro categorías corresponden a tareas asociadas al equipo de trabajo, mientras que la quinta corresponde a las tareas de la contraparte.

BIBLIOGRAFIA

- Angelico R., Basso M., Candusso M., Grimaldi C., Liccardo D., Maggiore G., Mosca A., Paoletti M., Pietrobattista A., Safarikia S., Saffioti M. y Spada M. (Noviembre, 2020). *A novel mobile phone application for infant stool color recognition: An easy and effective tool to identify acholic stools in newborns.* <https://journals.sagepub.com/doi/full/10.1177/0969141320974413#table4-0969141320974413>.
- Borgeat M., Korffl S. y Wildhaber B. (Mayo, 2018). *Newborn biliary atresia screening with the stool colour card: a questionnaire survey of parents.* BMJ Journals. <https://bmjpaedsopen.bmj.com/content/2/1/e000269>.
- Brett M. (2016). *Otsu's method for binarizing images.* Github. https://bic-berkeley.github.io/psych-214-fall-2016/otsu_threshold.html.
- Dugdale D. y Schwartz C. (2024). *Atresia Biliar.* Medline Plus. <https://medlineplus.gov/spanish/ency/article/001145.htm>.
- Poocharoen W., Suttiwongsing A., Tangkabuanbutr P., Treeprapin K., Trirongchitmoh C., Trirongjitmoah S., Waitayagitgumjon K. y Wirifai T. (Mayo, 2024). *A Multicenter Pilot Study of Biliary Atresia Screening Using Digital Stool Color Imaging.* PubMed Central. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11134179/#sec12>.
- Sapkota R. y Karkee M. (15 de octubre, 2025). *ULTRALYTICS YOLO EVOLUTION: AN OVERVIEW OF YOLO26, YOLO11, YOLOV8, AND YOLOV5 OBJECT DETECTORS FOR COMPUTER VISION AND PATTERN RECOGNITION.* arXiv. <https://doi.org/10.48550/arXiv.2510.09653>.
- Shahinfar S., Meek P. y Falzon G. (2020). *"How many images do I need?" Understanding how sample size per class affects deep learning model performance metrics for balanced designs in autonomous wildlife monitoring.* Ecological Informatics. <https://doi.org/10.1016/j.ecoinf.2020.101085>.
- Song J., Kim D., Jeong E. y Park J. (28 de marzo, 2025). *Determination of Optimal Dataset Characteristics for Improving YOLO Performance in Agricultural Object Detection.* Agriculture. <https://doi.org/10.3390/agriculture15070731>.

UC Christus. (Mayo, 2023). *Conoce el Lado B del Dr. Juan Carlos Pattillo, Cirujano Pediátrico y Director Médico Hospital Clínico UC CHRISTUS*. UC Christus. <https://www.ucchristus.cl/blog-salud-uc/articulos/2023/el-lado-b-del-dr.-juan-carlos-pattillo--cirujano-pediátrico-y-director-médico-hospital-clínico-uc-christus>.

UC Christus. (2026). *¿Quiénes somos? Atención Médica*. UC Christus. <https://www.ucchristus.cl/informacion-al-paciente/quienes-somos>.